

Материалы к презентации ИИ агенты в закупках


АЛЕКСЕЙ РУБЛЕВ

Что нужно



Локальная LLM

Большинство компаний ограничено в использовании облачных LLM в целях безопасности



Интерфейс

Продукт через который вы общаетесь с пользователем: Telegram, Bitrix, ...



Чат бот

Механизм чат-ботов
Которые реализуют базовые механики взаимодействия



Skills/Tools

Инструменты интеграции и навыки которые эти инструменты используют


Локальная LLM: Настройка ОС



Установка ОС: <https://ubuntu.com/tutorials/install-ubuntu-server>

Настройка драйверов видеокарты:

```
#sudo ubuntu-drivers list --gpgpu
#sudo ubuntu-drivers install --gpgpu
#sudo apt install nvidia-driver-570-server
#sudo apt install -y nvidia-cuda-toolkit
#nvida-smi
```



```
sandbox@msk-ai-sandbox:~$ nvidia-smi
Wed Apr 29 13:02:46 2026
+-----+
| NVIDIA-SMI 570.211.01                  Driver Version: 570.211.01      CUDA Version: 12.8     |
+-----+-----+
| GPU   Name                               Persistence-M | Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan   Temp   Perf              Pwr:Usage/Cap |      Memory-Usage | GPU-Util  Compute M. |
|                               Pwr:Usage/Cap |      Memory-Usage | GPU-Util  Compute M. |
|-----+-----+-----+
| 0     NVIDIA GeForce RTX 2080 Ti        Off          00000000:01:00:00 Off |      0MiB / 22528MiB |      0%      Default |
| 25%    38C    P0              35W / 260W |      0MiB / 22528MiB |      0%      Default |
+-----+-----+-----+
+-----+
| Processes:                               |
|  GPU   GI    CI          PID    Type    Process name                        GPU Memory |
|          ID    ID                                   Usage   |
+-----+-----+
| No running processes found              |
+-----+
```

Локальная LLM: Настройка и запуск LLM



#Создаем директорию под библиотеки

```
cd ../home/{имя пользователя}
```

```
mkdir vllm
```

```
cd vllm
```

Устанавливаем Python

```
sudo apt install python3.12 python3.12-venv python3.12-distutils -y python3-pip
```

#Устанавливаем виртуальное окружение для vllm

```
python3 -m venv .venv
```

```
source .venv/bin/activate
```

#Устанавливаем инференс движок vLLM для запуска нейросети

```
pip install vllm
```

#Запуск vLLM+Qwen3 (тестовый)

```
python -m vllm.entrypoints.openai.api_server --model Qwen/Qwen3-14B-AWQ --host 0.0.0.0  
--port 8002 --gpu-memory-utilization 0.85 --max-model-len 8192 --quantization awq
```


Локальная LLM: Запуск LLM



```
(sandbox) sandbox@msk-ai-sandbox:~$ python -m vllm.entrypoints.openai.api_server --model Qwen/Qwen3-14B-AWQ --host 0.0.0.0 --port 8002 --gpu-memory-utilization 0.85 --max-model-len 8192 --quantization awq --trust-remote-code
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:302]
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:302]
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:302]
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:302]
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:302]
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:302]
(APISServer pid=108432) INFO 04-29 13:05:46 [utils.py:238] non-default args: {'host': '0.0.0.0', 'port': 8002, 'model': 'Qwen/Qwen3-14B-AWQ', 'trust_remote_code': True, 'max_model_len': 8192, 'quantization': 'awq', 'gpu memory utilization': 0.85}
```

```
(APIServer pid=108432) INFO 04-29 13:09:22 [api_server.py:500] Starting vLLM API server 0 on http://0.0.0.0:8002
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:38] Available routes are:
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /openapi.json, Methods: HEAD, GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /docs, Methods: HEAD, GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /docs/oauth2-redirect, Methods: HEAD, GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /redoc, Methods: HEAD, GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /tokenize, Methods: POST
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /detokenize, Methods: POST
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /load, Methods: GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /version, Methods: GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /health, Methods: GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /metrics, Methods: GET
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/mo$andbox@msk-ai-sandbox:~$ nvidia-smi
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /ping, Wed Apr 29 12:36:45 2026
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /ping,
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /invoca
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/ch| NVIDIA-SMI 570.211.01
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/ch|
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/re|
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/re| GPU Name Persisten
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/re| Fan Temp Perf Pwr:Usag
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/cor|
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/cor|
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/me|
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /v1/me| 0 NVIDIA GeForce RTX 2080 Ti
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /infer| 27% 35C P8 25W /
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /scale_
(APIServer pid=108432) INFO 04-29 13:09:22 [launcher.py:47] Route: /is_sc|
(APIServer pid=108432) INFO: Started server process [108432]
(APIServer pid=108432) INFO: Waiting for application startup.
(APIServer pid=108432) INFO: Application startup complete.
```

Processes:							
GPU	GI	CI	PID	Type	Process name	GPU Memory	Usage
	ID	ID					
0	N/A	N/A	95217	C	VLLM::EngineCore	20898MiB	

#Проверяем запуск LLM

Сервер запущен, LLM загружена в видео память

Локальная LLM: Тест



#Проверяем ответ LLM

```
curl http://localhost:8002/v1/chat/completions -H "Content-Type: application/json" -d '{
  "model": "Qwen/Qwen3-14B-AWQ",
  "messages": [
    {
      "role": "user",
      "content": "Кто ты и кто тебя создал?"
    }
  ],
  "max_tokens": 256
}'
```

```
sandbox@msk-ai-sandbox: ~
(sandbox) sandbox@msk-ai-sandbox:~$ curl http://localhost:8002/v1/chat/completions -H "Content-Type: applica
tion/json" -d '{
  "model": "Qwen/Qwen3-14B-AWQ",
  "messages": [
    {
      "role": "user",
      "content": "Кто ты и кто тебя создал?"
    }
  ],
  "max_tokens": 256
}'
{"id":"chatcmpl-ab1f630c3ca848e8","object":"chat.completion","created":1777468937,"model":"Qwen/Qwen3-14B-AWQ",
,"choices":[{"index":0,"message":{"role":"assistant","content":"<think>\nХорошо, пользователь спрашивает, кт
о я и кто меня создал. Нужно дать четкий и точный ответ. Сначала представлюсь как Qwen, крупнейшая языковая м
одель, разработанная Alibaba Cloud. Важно упомянуть, что я был разработан командой Alibaba Cloud, чтобы польз
ователь знал, откуда я. Также стоит добавить, что я могу помочь в различных задачах, чтобы показать свою поле
зность. Нужно сохранить ответ дружелюбным и информативным, без лишних деталей. Проверю, нет ли ошибок в назва
ниях и структуре ответа. Всё готово.\n</think>\n\nЯ Qwen, крупнейшая языковая модель, разработанная Alibaba C
loud. Я был создан командой инженеров и исследователей Alibaba Cloud, которые стремятся создать более мощные
и интеллектуальные модели, способные помогать людям в различных задачах. Если у вас есть какие-либо вопросы и
ли вам нужна помощь, пожалуйста, не","refusal":null,"annotations":null,"audio":null,"function_call":null,"too
l_calls":[],"reasoning":null},"logprobs":null,"finish_reason":"length","stop_reason":null,"token_ids":null}],
"service_tier":null,"system_fingerprint":null,"usage":{"prompt_tokens":17,"total_tokens":273,"completion_toke
ns":256,"prompt_tokens_details":null},"prompt_logprobs":null,"prompt_token_ids":null,"kv_transfer_params":nul
l}
(sandbox) sandbox@msk-ai-sandbox:~$
```


Локальная LLM: Запускаем сервис



#создаем файл настроек
sudo nano /etc/systemd/system/vllm-qwen3.service
#пример файла конфигурации



vllm.example.config.txt

Перезагрузить systemd
sudo systemctl daemon-reload
Включить автозапуск
sudo systemctl enable vllm-qwen3.service
Запустить сервис
sudo systemctl start vllm-qwen3.service
Проверить статус
sudo systemctl status vllm-qwen3.service
Посмотреть логи
sudo journalctl -u vllm-qwen3.service -f

```
(sandbox) sandbox@msk-ai-sandbox:~$ sudo nano /etc/systemd/system/vllm-qwen3.service
(sandbox) sandbox@msk-ai-sandbox:~$ sudo systemctl start vllm-qwen3.service
(sandbox) sandbox@msk-ai-sandbox:~$ sudo journalctl -u vllm-qwen3.service -f
anp 29 13:02:05 msk-ai-sandbox systemd[1]: Stopping vllm-qwen3.service - vLLM Qwen3-14B Server...
anp 29 13:02:05 msk-ai-sandbox vllm-qwen3[94708]: (APIServer pid=94708) INFO 04-29 13:02:05 [launcher.py:122] Shutting down FastAPI HTTP server.
anp 29 13:02:07 msk-ai-sandbox vllm-qwen3[95217]: [rank0]:[W429 13:02:07.130185994 ProcessGroupNCCL.cpp:1553] Warning: WARNING: destroy_process_group which can leak resources. For more info, please see https://pytorch.org/docs/stable/distributed.html#shutdown (function operator())
anp 29 13:02:10 msk-ai-sandbox vllm-qwen3[94708]: (APIServer pid=94708) INFO: Shutting down
anp 29 13:02:11 msk-ai-sandbox vllm-qwen3[94708]: (APIServer pid=94708) INFO: Waiting for application shutdown.
anp 29 13:02:11 msk-ai-sandbox vllm-qwen3[94708]: (APIServer pid=94708) INFO: Application shutdown complete.
anp 29 13:02:15 msk-ai-sandbox systemd[1]: vllm-qwen3.service: Deactivated successfully.
anp 29 13:02:15 msk-ai-sandbox systemd[1]: Stopped vllm-qwen3.service - vLLM Qwen3-14B Server.
anp 29 13:02:15 msk-ai-sandbox systemd[1]: vllm-qwen3.service: Consumed 1h 51min 5.872s CPU time.
anp 29 13:02:26 msk-ai-sandbox systemd[1]: Started vllm-qwen3.service - vLLM Qwen3-14B Server.
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:302]
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:302]
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:302]
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:302]
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:302]
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:302]
anp 29 13:38:47 msk-ai-sandbox vllm-qwen3[109489]: (APIServer pid=109489) INFO 04-29 13:38:47 [utils.py:238] non-default args: {'model_tag': '\l_parser': 'hermes', 'host': '0.0.0.0', 'port': 8002, 'api_key': ['b1057112174f710070c038843db883ed2c6d64b3ee3306494783b49fad710569']], 'model': 'ue, 'dtype': 'half', 'max_model_len': 60000, 'quantization': 'awq', 'enforce_eager': True, 'served_model_name': ['qwen3-14b'], 'hf_overrides': {'': 4.0, 'original_max_position_embeddings': 32768}}, 'gpu_memory_utilization': 0.94, 'enable_prefix_caching': True, 'max_num_seqs': 1, 'enable_ch
```



ИИ Агент + Telegram за 1 мин

1. Создаем бота в Telegram ([инструкция](#))



2. Установка агента:

2.1 Установка Python ([инструкция](#))

2.2 Установка менеджера пакетов Pip и Сертификатов SSL

```
#py -m ensurepip --upgrade
```

```
#pip install pip-system-certs
```

2.3 Установка Nanobot ([инструкция](#))

```
# pip install nanobot-ai
```



ИИ Агент + Telegram за 1 мин



3. Настройка агента

3.1 Создаем файл настроек

nanobot onboard

```
(base) C:\Windows\System32>nanobot onboard
✓ Created config at C:\Users\rublev.an\.nanobot\config.json
Created AGENTS.md
Created HEARTBEAT.md
Created SOUL.md
Created TOOLS.md
Created USER.md
Created memory\MEMORY.md
Created memory\history.jsonl
2026-05-25 11:48:44 | INFO | - | Git store initialized at C:\Users\rublev.an\.nanobot\workspace
🐱 nanobot is ready!
```

3.2 Редактируем созданный файл и подключаем LLM Модель и Telegram – [config.json](#)

3.3. Запускаем агента # nanobot gateway

```
(base) C:\Windows\System32>nanobot gateway
🐱 Starting nanobot gateway version 0.2.0 on port 18790...
2026-05-25 12:42:56 | INFO | - | Registered 15 tools: ['complete_goal', 'cron', 'edit_file', 'exec', 'grep', 'list_dir',
'long_task', 'message', 'notebook_edit', 'read_file', 'spawn', 'web_fetch', 'web_search', 'write_file', 'my']
2026-05-25 12:43:13 | INFO | - | Telegram channel enabled
✓ Channels enabled: telegram
✓ Cron: 1 scheduled jobs
✓ Heartbeat: every 1800s
2026-05-25 12:43:13 | INFO | - | Cron: registered system job 'dream' (dream)
✓ Dream: every 2h
2026-05-25 12:43:13 | INFO | - | Cron service started with 1 jobs
2026-05-25 12:43:13 | INFO | - | Heartbeat started (every 1800s)
2026-05-25 12:43:13 | INFO | - | Agent loop started
2026-05-25 12:43:13 | INFO | - | Starting telegram channel...
2026-05-25 12:43:13 | INFO | - | Outbound dispatcher started
2026-05-25 12:43:14 | INFO | telegram | Starting bot (polling mode)...
✓ Health endpoint: http://127.0.0.1:18790/health
2026-05-25 12:43:15 | INFO | telegram | bot @testBidzar1bot connected
```

ИИ Агент + Telegram за 1 мин

Агент готов к использованию!

Теперь дополнительно можем задать в настройках Навыки и наборы инструментов:

1) mcp server в файле ~/.nanobot/config.json

```
"mcpServers": {  
  "bidzaar": {  
    "command": "python",  
    "args":  
    [ "~/.nanobot/workspace/mcp/bidzaar/bidzaar_mcp.py"]  
  },  
},
```

2) Навыки скопировать в ~/.nanobot/workspace/skills/

